*Mini Project 01 - TOP IMDB

```
#install.packages("tidyverse") -> for program r
#install.packages("rvest") -> for program r
library(tidyverse)
library(rvest) # scrape data from internet
url <- "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating%2Cd</pre>
print(url)
[1] "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating%2Cde
#read HTML
imdb <- read_html(url)</pre>
imdb
{html_document}
<html xmlns:og="http://ogp.me/ns#" xmlns:fb="http://www.facebook.com/2008/fb
[1] <head>\n<meta http-equiv="Content-Type" content="text/html; charset=UTF-
[2] <body id="styleguide-v2" class="fixed">\n
                                                            <imq height="1" wid</pre>
#movie title
titles <- imdb %>%
    html_nodes("h3,lister-item-header")%>% #node คือ ดึงแค่ชื่อแรก nodes คือ ดึงทุกชื่อ
    html_text2()%>% #text ดึงอักขระแปลกๆมาด้วย text2 ดึงแค่ชื่อ
    head
```

```
'1. The Shawshank Redemption (1994)' · '2. The Godfather (1972)' · '3. The Dark Knight (2008)' ·
```

```
'4. Schindler\'s List (1993)' · '5. The Godfather Part II (1974)' · '6. 12 Angry Men (1957)' · NA · NA · NA · NA
```

```
#rating
ratings <- imdb%>%
  html_nodes("div.ratings-imdb-rating") %>%
  html_text2()%>%
  as.numeric()%>%
  head
```

```
ratings[1:10]
```

```
9.3 · 9.2 · 9 · 9 · 9 · 9 · < NA> · < NA> · < NA> · < NA>
```

```
#number of vote
num_votes <- imdb%>%
  html_nodes("p.sort-num_votes-visible")%>%
  html_text2()%>%
  head
```

```
num_votes
```

```
'Votes: 2,699,167 | Gross: $28.34M | Top 250: #1' · 'Votes: 1,873,368 | Gross: $134.97M | Top 250: #2' · 'Votes: 2,672,895 | Gross: $534.86M | Top 250: #3' · 'Votes: 1,364,525 | Gross: $96.90M | Top 250: #6' · 'Votes: 1,280,233 | Gross: $57.30M | Top 250: #4' · 'Votes: 797,150 | Gross: $4.36M | Top 250: #5'
```

```
#build a database
df <- data.frame(
    title = titles,
    rating = ratings,
    num_vote = num_votes
)
head(df)</pre>
```

A data.frame: 6 × 3

	7. 00.0011011010						
	title	rating	num_vote				
	<chr></chr>	<dbl></dbl>	<chr></chr>				
1	1. The Shawshank Redemption (1994)	9.3	Votes: 2,699,167 Gross: \$28.34M Top 250: #1				
2	2. The Godfather (1972)	9.2	Votes: 1,873,368 Gross: \$134.97M Top 250: #2				
3	3. The Dark Knight (2008)	9.0	Votes: 2,672,895 Gross: \$534.86M Top 250: #3				
4	4. Schindler's List (1993)	9.0	Votes: 1,364,525 Gross: \$96.90M Top 250: #6				
5	5. The Godfather Part II (1974)	9.0	Votes: 1,280,233 Gross: \$57.30M Top 250: #4				
6	6. 12 Angry Men (1957)	9.0	Votes: 797,150 Gross: \$4.36M Top 250: #5				

df

A data.frame: 51 × 1
title
<chr></chr>
1. The Shawshank Redemption (1994)
2. The Godfather (1972)
3. The Dark Knight (2008)
4. Schindler's List (1993)
5. The Godfather Part II (1974)
6. 12 Angry Men (1957)
7. The Lord of the Rings: The Return of the King (2003)
8. Pulp Fiction (1994)
9. Inception (2010)
10. Fight Club (1999)
11. The Lord of the Rings: The Fellowship of the Ring (2001)
12. Forrest Gump (1994)
13. Il buono, il brutto, il cattivo (1966)
14. The Lord of the Rings: The Two Towers (2002)
15. GoodFellas (1990)
16. The Matrix (1999)
17. One Flew Over the Cuckoo's Nest (1975)
18. The Empire Strikes Back (1980)
19. Interstellar (2014)
20. Se7en (1995)
21. The Silence of the Lambs (1991)
22. Saving Private Ryan (1998)
23. The Green Mile (1999)
24. Star Wars (1977)
25. La vita è bella (1997)
26. Terminator 2: Judgment Day (1991)
27. Sen to Chihiro no kamikakushi (2001)
28. Cidade de Deus (2002)
29. It's a Wonderful Life (1946)
30. Shichinin no samurai (1954)
31. Seppuku (1962)
32. Whiplash (2014)
33. Gisaengchung (2019)
34. Gladiator (2000)
35. The Departed (2006)
36. Léon (1994)
37. The Prestige (2006)
38. Apocalypse Now (1979)
39. Back to the Future (1985)
40. Alien (1979)
41. The Lion King (1994)
42. The Usual Suspects (1995)
42. The Osual Suspects (1995)

```
43. American History X (1998)
44. The Pianist (2002)
45. Casablanca (1942)
```

** Mini Project 02 - Specphone Phone project

- 48. Once Upon a Time in the West (1968)
- 49. Hotaru no haka (1988)
- 50. Rear Window (1954)

library(tidyverse) library(rvest) # scrape data from internet

url<-read_html("https://specphone.com/Samsung-Galaxy-A04.html")</pre>

```
att <- url %>%
   html_nodes("div.topic")%>%
    html_text2()
value <- url%>%
    html_nodes("div.detail")%>%
    html_text2()
```

data_frame(attitude= att,value=value)

A tibble: 31 × 2

A TIDDIE: 31 × 2					
attitude	value				
<chr></chr>	<chr></chr>				
วันเปิดตัว	ตุลาคม 2565				
วันวางจำหน่าย	ยังไม่วางจำหน่าย				
ขนาด	164.40 x 76.30 x 9.10 มม.				
น้ำหนัก	192 กรัม				
วัสดุ	Glass front, plastic back, plastic frame				
SIM	รองรับ 2 ซิมการ์ด (nano sim, nano sim)				
Technology	HSPA 42.2/5.76 Mbps, LTE-A				
2G	850/900/1800/1900				
3G	850/900/1900/2100				
4G	850/900/1900/2100/2600				
5G	-				
ความเร็ว	HSPA 42.2/5.76 Mbps, LTE-A				
ประเภท	PLS LCD				
ขนาดหน้าจอ	6.50 นิ้ว				
ความละเอียด	720 x 1600 pixels				
ระบบปฏิบัติการ	Android 12				
ชิปประมวลผล	Spreadtrum Unisoc SC9863A 1.6 GHz				
ชิปกราฟิก	PowerVR GE8322				
หน่วยความจำ	3 GB				
ความจุ	32 GB				
Memory Card	microSD (1)				
กล้องหลัก	ตัวที่ 1: 50 MP, f/1.8, (wide), AF ตัวที่ 2: 2 MP, f/2.4, (depth)				
ความละเอียดวีดีโอ	1080p@30fps				
กล้องหน้า	ตัวที่ 1: 5 MP, f/2.2				
Bluetooth	5.0, A2DP, LE				
Wi-Fi	802.11 a/b/g/n/ac, dual-b				
USB	Туре-С				
GPS	GLONASS, GALILEO, BDS				
NFC	ไม่รองรับ				
ความจุ	5,000 mAh				
ประเภท	Non-removable Li-Po Batt				

```
#link to all samsung smartphone
links <- samsung_url %>%
   html_nodes("li.mobile-brand-item a") %>%
   html_attr("href")
```

```
full_links <- paste0("http://specphone.com",links)</pre>
```

```
result <- data.frame()</pre>
for (link in full_links[1:5]){
    ss_topic <- link %>%
        read_html()%>%
        html_nodes("div.topic")%>%
        html_text2()
    ss_detail <- link %>%
        read_html()%>%
        html_nodes("div.detail")%>%
        html_text2()
    tmp <- data.frame(attitude = ss_topic,</pre>
                         value=ss_detail)
    result <- bind_rows(result,tmp)</pre>
    print("Progress ...")
print(head(result),3)
[1] "Progress ..."
     attitude
                                                    value
      วันเปิดตัว
                                             มิถุนายน 2565
1
2 วันวางจำหน่าย
                                           ยังไม่วางจำหน่าย
3
                              165.40 x 76.90 x 8.40 มม.
         ขนาด
4
        น้ำหนัก
                                                  192 กรัม
          วัสดุ Glass front, plastic back, plastic frame
5
          SIM รองรับ 2 ซิมการ์ด (nano sim, nano sim)
```

```
#write csv
write_csv(result, "result_ss_phone.csv")
```